

**Taller – 2 :** Jairo Antonio Caro Vanegas , Andrés Fernando Delgado Pérez.

### **Entendimiento y preparación de los datos:**

Para el ejercicio propuesto segmentamos los datos en dos conjuntos globales de entrenamiento, el primero será para entrenar el modelo con base en la clase del producto sin discriminar por marcas, para este conjunto inicialmente contamos con 1776 número de imágenes de entrenamiento, 1704 imágenes para realizar el test y 296 imágenes de validación, en la validación observamos que cada una de las imágenes cuenta con una matriz RGB donde cada uno de sus pixeles tiene un valor que oscila entre los valores de 1 y 255, teniendo en cuenta esto se realizó un reescalado dividiendo cada uno de los valores en 255 , al conjunto de datos de entrenamiento se le realizo un cambio de tamaño en la imagen a una altura de 348 y una ancho de 348 para estandarizar todas estas, para tener mas datos de entrenamiento se crearon nuevas imágenes de tal manera que cada una de estas tuviese 3 copias, una rotada horizontalmente, otra rotada verticalmente y una última girada 90 grados, con este cambio al final del ejercicio terminamos con 7104 imágenes de test y 34 etiquetas de entrenamiento.

Para el siguiente caso de uso donde si discriminamos los productos por marca lo primero que realizamos fue una copia de las carpetas test, train con el fin de poder obtener sus etiquetas correspondientes, y en los valores como “Avocado” que no cuentan con una segmentación por marca le dejamos su etiqueta normal, para este ejercicio contamos con todas nuestras imágenes y categorías, teniendo esto en cuenta al final quedamos con 10560 imágenes para test esto debido a que se le realizo el mismo tratamiento de creación de nuevas imágenes que al requerimiento anterior, contamos con 2485 imágenes de test y 296 imágenes de validación, al conjunto de entrenamiento adicionalmente también se le realizo los mismos reescalados del punto anterior, con este tratamiento al final contamos con las 10560 imágenes y 81 etiquetas para entrenar.

### **Entrenamiento del modelo de Machine Learning:**

Para este punto realizamos dos modelos de entrenamiento uno basado en el algoritmo de RandomForestClassifier y el otro basado en una red convolucional previamente entrenada MobileNetV2, para el primer caso utilizamos los dos modelos con el fin de comparar rendimiento, pero para el segundo caso utilizamos únicamente la red convolucional.

Para poder visualizar el entrenamiento dividimos en tres archivos cada uno de los casos tal que en el archivo "MobileNet\_marcas.ipynb" encontraremos el entrenamiento para el primer caso de uso con la red convolucional, en el archivo "MobileNet\_marcas.ipynb" encontraremos el entrenamiento para el segundo caso de uso con la red convolucional y finalmente en el archivo "RandomForest.ipynb" encontraremos nuestro entrenamiento con el algoritmo RandomForestClassifier para el primer caso de uso.

### **Análisis de resultados del modelo:**

Para las métricas de los modelos decidimos calcular la precisión, recall y el f1.

Para el modelo "MobileNet\_marcas.ipynb" obtuvimos

- Precisión: - Test: 0.88
- Recall: - Test: 0.86
- F1: - Test: 0.85

Esto nos indica que el modelo tiene un buen desempeño a la hora de calcular los falsos positivos, pero pierde un pequeño porcentaje de valores correctos (Falsos negativos), en cuanto al F1 vemos que el modelo tiene un buen balance, pero el valor inferior de recall sugiere que el modelo sacrifica recall para mejorar precisión.

En cuanto a los resultados en la matriz de confusión (disponible en “MobileNet\_marcas.ipynb” ) obtuvimos que hay una clara tendencia a identificar de forma correcta lo productos teniendo una diagonal bastante marcada donde en la mayoría de los casos cumple con la predicción, la desviación más clara en la curva es en el caso de la predicción para la categoría 38 (Golden-Delicious) vemos que suele predecirla como la categoría 39 (Granny-Smith) esto puede deberse a la similitud de las imágenes de entrenamiento al pertenecer a la misma fruta con un color parecido, al igual que en otra clase la desviación entre los productos Flourey-Potato y Solid-Potato por la similitud de las imágenes.

(Golden-Delicious)




(Granny-Smith)



Para probar los modelos, tomamos unas cuantas fotos de ejemplo por categoría con el fin de buscar la precisión con diferentes entornos y productos en esta prueba tuvimos algunos problemas con lo producto ya que se mapeo que el algoritmo esta bastante sesgado a que las imágenes coincidan con las de entrenamiento, para esto se recomienda reentrenar el modelo constantemente con nuevas imágenes y de mejor calidad ya que en el conjunto de entrenamiento se evidencia categorías que en su mayoría cuentan con imágenes bastante borrosas.

Cuando contamos con mayor variedad de imágenes y con una mejor resolución el algoritmo funciona de mejor manera, esto lo evidenciamos con la capacidad de interpretar correctamente las manzanas en las imágenes capturadas por nosotros.



(Imagen disponible en el archivo)

Para el modelo “MobileNet\_no\_marcas.ipynb” obtuvimos


- Precisión: - Test 0.57
- Recall: - Test: 0.58
- F1: - Test: 0.57

Esto nos indica que este modelo está generando una alta tasa de falos positivos a la par está perdiendo una cantidad alta de imágenes positivas, el f1 es un valor bastante bajo con lo que podemos concluir que el modelo no es confiable para la predicción.

Analizando los datos usando para el entrenamiento podemos concluir que el desbalance entre las clases es muy significativo en donde para clases como mazana podemos tener más de 100 imágenes, pero para clases como hongos únicamente tenemos 20 imágenes, esto nos puede llevar a que esta mala precisión mayormente se presente en categorías con menos imágenes y de menor cantidad, esta tendencia la podemos validar en la matriz del modelo (disponible en

“MobileNet\_no\_marcas.ipynb”) donde tenemos 11 categorías que se desvían considerablemente de la curva,

Este modelo a nivel de negocio podría utilizarse en categorías específicas como las manzanas u otras frutas, esto lo validamos con imágenes capturadas por nosotros en donde el modelo tuvo un buen desempeño para categorizar frutas.



(Imagen disponible en el archivo)

Para el modelo “RandomForest.ipynb” obtuvimos

- Precisión: - Test 0.12
- Recall: - Test 0.19
- F1: - Test: 0.13

Con estos valores podemos concluir que este modelo es ineficiente para la tarea, esto se puede deber al desbalance de las categorías en donde esta al no ser un algoritmo preentrenado, le es mas complejo segmentar mejor las imágenes.



Este modelo a nivel de negocio no se recomienda usar ya que no servirá de una forma correcta para la motivación del negocio.

## **Generación de valor**

Dentro de los beneficios de la solución implementada encontramos reducción de FTEs y sus costos implicados (nómina) con la automatización de identificación y conteo de producto recibido, su inventariado y frente a ventas la automatización del pago de los clientes.

En primera instancia, el sistema es capaz de identificar con cámaras los tipos de fruta y verdura que llegan del proveedor del almacén. El proceso actual consta de 8 trabajadores abriendo cajas y anotando el producto recibido. El promedio de horas trabajadas es de 1024 hr al mes (32 por semana para esta actividad por recurso). Durante la jornada, se abren las cajas, el producto se identifica y cuenta y posteriormente se pasa a inventario, donde 2 recursos se encargan de actualizar este mientras otros trabajadores (no involucrados en el caso de negocio) se encargan de almacenar en bodega. Los encargados del inventario destinan 256 hr al mes en esta actividad (32 por semana para esta actividad por recurso).

Siguiendo con el proceso de venta y facturación, se implementa un nuevo sistema que permite al cliente poner sus compras en una banda transportadora (ya existente) y que una cámara se encargue de tomar fotos y mandar la información a un sistema de procesamiento donde se identifiquen los productos a facturar. Este proceso actualmente lo realizan 10 personas, destinan 32 hr a la semana cada uno a esto, con 1280 hr al mes en total. A continuación, un resumen del proceso actual analizado (160 hr de trabajo al mes):

Actividad	Recursos	Horas trabajo	FTE
Identificar tipo de fruta/vegetal	8	1024	6.4
Actualizar inventario	2	256	1.6
Caja y facturación	10	1280	8
<b>total</b>	<b>20</b>	<b>2560</b>	<b>16</b>

Las 8 horas de cada trabajador restantes de la semana se distribuyen en actividades internas de la empresa. Con respecto a los salarios, se calculan en base al salario mínimo (\$ 1.300.000) y se ajustan dependiendo del cargo. Se adicionan gastos de salud y pensión (entre otros) para mostrar el costo completo que recurre la empresa mes a mes (se incluye prima del año) en nómina:

Recurso	Actividad	Salario (c/u)	Cantidad personal	Total
<b>Bodega</b>	Identificar tipo de fruta/vegetal	\$ 2,340,000.00	8	<b>\$ 18,720,000.00</b>
<b>Bodega 2</b>	Actualizar inventario	\$ 2,808,000.00	2	<b>\$ 5,616,000.00</b>
<b>Cajero</b>	Caja y facturación	\$ 1,950,000.00	10	<b>\$ 19,500,000.00</b>
			<b>total</b>	<b>\$ 43,836,000.00</b>

Con la implementación de la solución, se plantea reducir en un 85% el personal en las áreas intervenidas. Para la bodega, se reduce a 1 recurso la supervisión de la operación, destinado a abrir cajas y posicionar el producto en las bandas transportadoras (ya existentes) para la clasificación con el modelo a entregar. Con

respecto a la caja, se disponen de 2 recursos para el servicio al cliente cuando se requiera. Las funciones, aunque cambian, no suponen un cambio en el salario:

Recurso	Actividad	Salario (c/u)	Cantidad personal	Total
<b>Bodega</b>	Identificar tipo de fruta/vegetal	\$ 2,340,000.00	1	<b>\$ 2,340,000.00</b>
<b>Bodega 2</b>	Actualizar inventario	\$ 2,808,000.00	0	<b>\$ -</b>
<b>Cajero</b>	Caja y facturación	\$ 1,950,000.00	2	<b>\$ 3,900,000.00</b>
			<b>total</b>	<b>\$ 6,240,000.00</b>

Siguiendo con costos de la implementación, se tiene la siguiente información:

Item	Costo (total proyecto)
<b>Equipo desarrollo</b>	<b>\$ 20,000,000.00</b>
<b>Nuevos equipos</b>	<b>\$ 50,000,000.00</b>
<b>Instalación</b>	<b>\$ 6,000,000.00</b>
<b>total</b>	<b>\$ 76,000,000.00</b>

El ítem de equipo de desarrollo incluye 2 desarrolladores que crearán y desplegarán la solución, son los encargados del levantamiento del proceso (es



una startup), la documentación funcional y técnica, el desarrollo, las pruebas y el paso a productivo. El ítem de nuevos equipos contiene:


- 10 cámaras para las cajas
- 5 cámaras para la bodega
- 1 servidor para ejecutar el modelo y procesar las imágenes
- 2 computadores para visualizar el proceso en tiempo real
- Licencia de pago único para facturación

La actividad de instalación será realizada en conjunto con una persona subcontratada por 2 semanas.

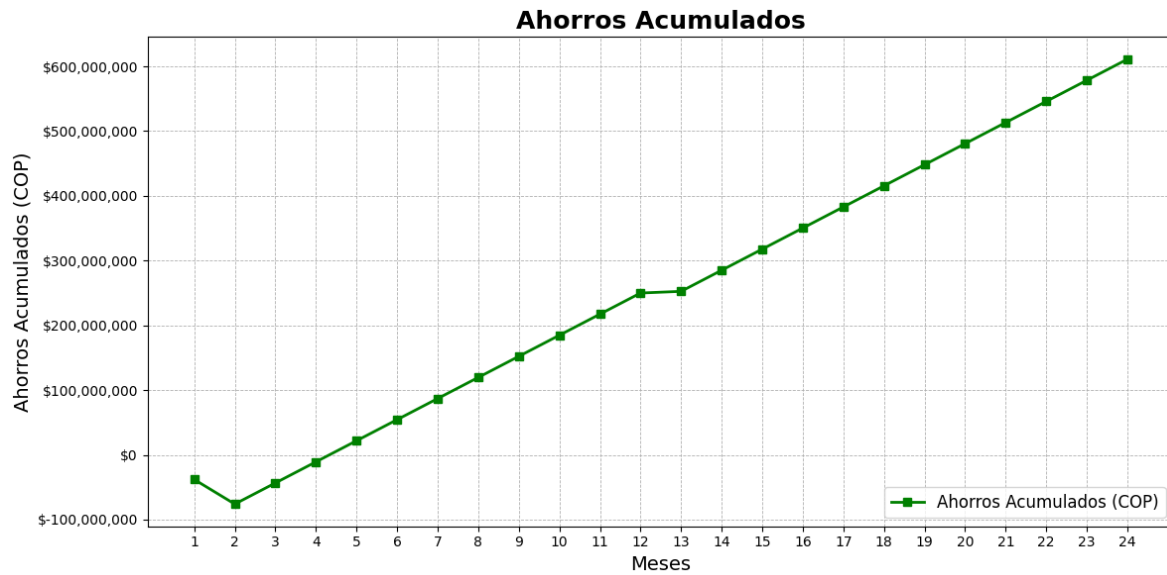
Adicionalmente, al mes 12 del inicio del proyecto, se realizará una actividad de mantenimiento a los dispositivos instalados y un reentrenamiento del modelo entregado. Este valor es de \$30.000.000 por ambas actividades y se pagará en un 100% al iniciar el mes. La operación de los sistemas y modelo actual no se interrumpirán durante estas actividades.

Por último, estos nuevos dispositivos suponen un consumo energético superior al actual, por lo cual se estima que \$5.000.000 adicionales al mes será destinado a cubrirlo (no se requiere instalación eléctrica nueva, la actual es capaz de soportar las nuevas demandas).


Con todo esto en mente, se presenta a continuación un gráfico detallando mes a mes, por 2 años, el flujo de caja relacionado al proyecto:



Se puede apreciar que durante los primeros dos meses se tiene un balance negativo, esto se debe al costo del proyecto y a la forma de pago (50% al iniciar, 50% al finalizar). Luego de esto no se perciben costos adicionales del proyecto hasta el mes 12, únicamente el ahorro de la nueva nómina mensual (\$37.596.000) y el nuevo gasto de la energía. En el mes 12 se presenta un costo por mantenimiento y reentrenamiento. Todo esto hace que se ahorre al mes un valor de \$32.596.000. Ahora visualizando la acumulación de ahorro:



Sumando cada valor mensual por dos meses resulta en un ahorro de \$611.112.000. Este valor supone que con una inversión de \$76.000.000 en dos años puede convertirse en un valor ahorrado de más de 600 millones:



Al finalizar el tiempo del caso de negocio se tendrá un ROI de 804% lo que significa que se prevé que la inversión generará, con costos permanentes (CAPEX), más de 8 veces lo invertido.

Como punto final, durante la operación del 4 mes de iniciado el proyecto, se verá la recuperación total de la inversión.

**Insight:**

Disponible en la presentación adjunta en el repositorio.

**Bono:**

La implementación del bono se hizo desde el algoritmo entrenado en el archivo "MobileNet\_marcas.ipynb".